

# Web Scraping e Datasets

Introdução ao web scraping com python



Nicolas de Sousa Maia nicolasdesousamaia@usp.br



# Kaggle

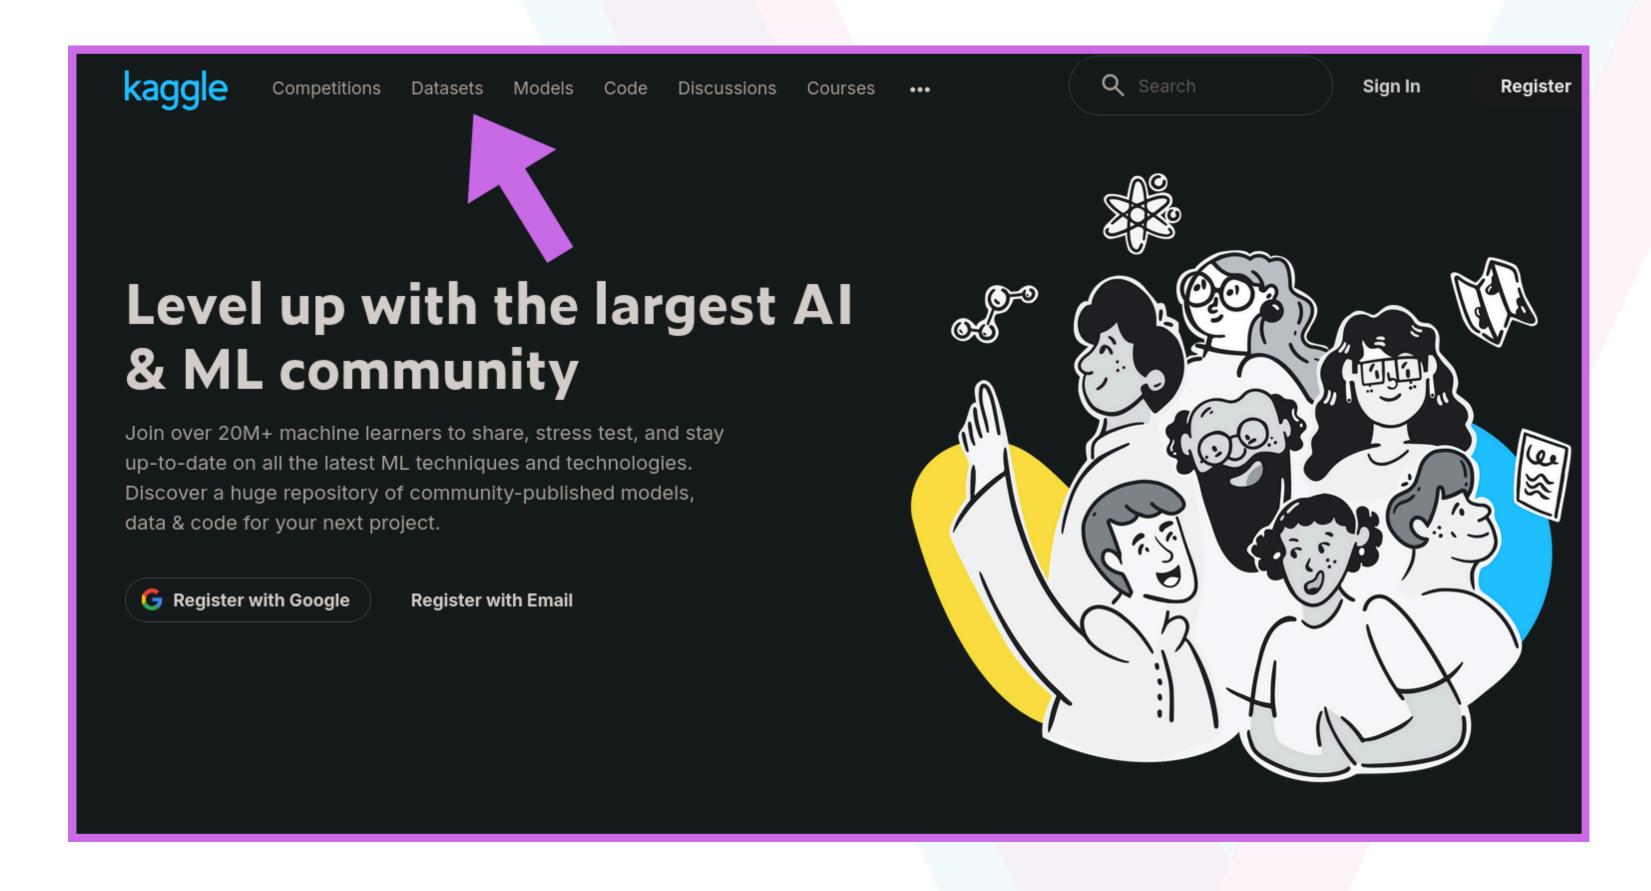


## Um pouco sobre o Kaggle

- subsidiária da Google
- comunidade de cientistas de dados e engenheiros de machine learning
- miríade de datasets
- competições e discussões de data science

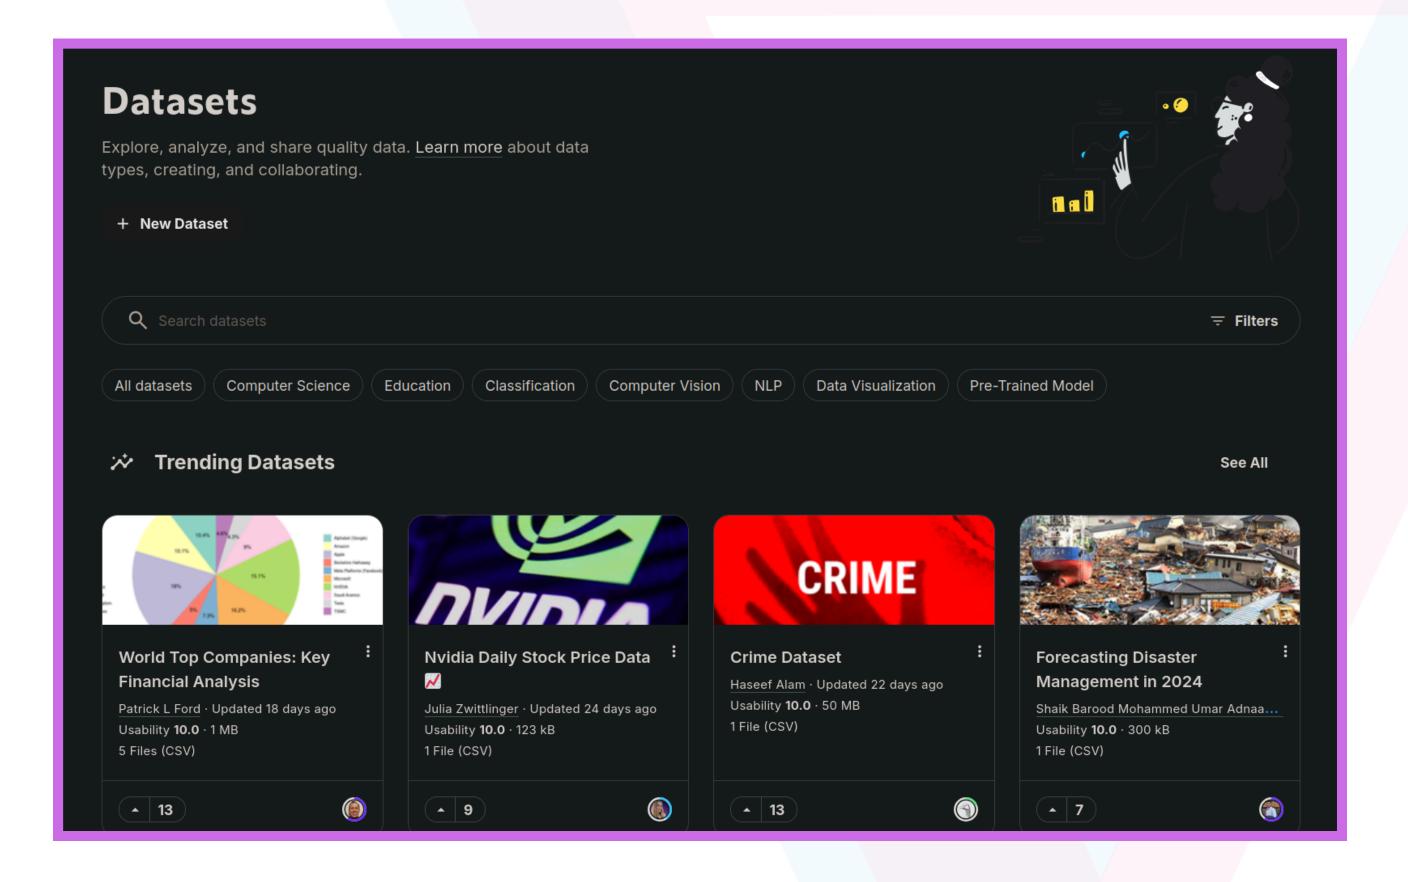


## Encontrando Datasets no Kaggle





### Variadade de Datasets





# Exemplo de Dataset



# Web Scraping



# O que é Web Scraping?

- técnica de extração automatizada de dados de sites na web
- converte o conteúdo de páginas HTML em informações estruturadas para análise ou uso posterior
- maneira de se obter um conjunto de dados de uma página web



# O que é uma página HTML?

- HTML = HyperText Markup Language
- linguagem usada para estruturar conteúdo na web
- Tags: <h1> <img>
- permite entender o formato de sites, facilitando a busca do dados desejados



# Montando uma página básica em HTML



# Como Web Scraping funciona

- Acessa páginas web como um navegador
- Identifica e extrai dados específicos (títulos, preços, imagens, valores)
- Armazena os dados em um formato útil, como CSV, JSON, ou bancos de dados



## Beautiful Soup

- biblioteca em Python que permite a extração de dados que estão em HTML
- útil para páginas estáticas
- ela e Requests são as principais livrarias utilizadas em Web Scraping desse tipo de página



## Selenium

- outra biblioteca disponível no Python, criada para lidar com sites feitos em JavaScript
- o programa torna-se capaz de simular um navegador
- permite ao programador o acesso aos dados de páginas dinâmicas



# Considerações Legais

#### Termos de Serviço (ToS):

 verifique sempre os ToS do site para garantir que o scraping é permitido

#### Leis de Proteção de Dados:

 GDPR/LGPD: evite coletar dados pessoais sem consentimento

#### Direitos Autorais:

 conteúdos protegidos por direitos autorais não devem ser reutilizados sem permissão



## Fim da aula